

SARS-CoV-2 Sequenzdaten aus Deutschland

Robert Koch-Institut

Zitieren

Robert Koch-Institut. (2026). SARS-CoV-2 Sequenzdaten aus Deutschland [Data set]. Zenodo.
<https://doi.org/10.5281/zenodo.21495400>

Zusammenfassung

Im Datensatz "SARS-CoV-2-Sequenzdaten aus Deutschland" umfasst vollständige Virusgenomsequenzen sowie zugehörige Metadaten aus bundesweit erhobenen Proben. Die Proben werden in Zusammenarbeit vom IMSSC2-Labornetzwerk, dem Nationalen Referenzzentrum für Coronaviren an der Charité sowie dem RKI sequenziert und bioinformatisch analysiert. Der Datensatz ermöglicht eine fundierte molekular-epidemiologische Analyse der SARS-CoV-2-Ausbreitung in Deutschland und stellt eine zentrale Ressource für Forschung und öffentliche Gesundheitsüberwachung dar.

Inhaltsverzeichnis

- [Informationen zum Datensatz und Entstehungskontext](#)
- [Aufbau und Inhalt des Datensatzes](#)
- [Hinweise zur Nachnutzung der Daten](#)

— [please find the English version here](#) —

Informationen zum Datensatz und Entstehungskontext

Ein zentraler Bestandteil einer erfolgreichen Erregersurveillance ist das Verständnis der Verbreitung eines Erregers sowie seiner pathogenen Eigenschaften. Hierbei stellt das Wissen über das Erregergenom eine wichtige Informationsquelle dar. So erlaubt der Nachweis von Mutationen im Genom eines Erregers, Verwandtschaftsbeziehungen zu rekonstruieren, Übertragungswege aufzudecken und Resistenzen vorherzusagen. Die Integrierte Genomische Surveillance (IGS) von SARS-CoV-2 zielt darauf ab, die Verbreitung des Virus und insbesondere von besorgniserregenden Virusvarianten in der Bevölkerung zu überwachen sowie auftretende Veränderungen des Virus genau zu beobachten. Besondere Bedeutung kommt dabei der öffentlichen Bereitstellung der genomischen Daten zu, um Wissenschaftlern in Deutschland und weltweit die Möglichkeit zu eigenständigen Analysen zu eröffnen.

Im Rahmen der [Coronavirus-Surveillanceverordnung](#) wurden bis zum 31.05.2023 [SARS-CoV-2 Sequenzdaten aus ganz Deutschland über den Deutschen Elektronischen Sequenzdaten-Hub \(DESH\) an das RKI übermittelt](#). Mit Ablauf der Verordnung werden künftig Proben durch das IMSSC2 Labornetzwerk bereitgestellt und am RKI sequenziert, analysiert und hier bereitgestellt. Trotz reduzierter Probenanzahl, wird durch die sorgfältige Auswahl der beteiligten Labore ein repräsentativer Einblick in die Viruspopulation gesichert ([Djin Ye Oh et al. 2022](#)). Zusätzlich werden Sequenzen vom NRZ Coronaviren an der Charité beigetragen um das IMSSC2 Netzwerk zu ergänzen.

Administrative und organisatorische Angaben

Der Datensatz "SARS-CoV-2-Sequenzdaten aus Deutschland" wird vom [Robert Koch-Institut](#) für Forschungsarbeiten im Zusammenhang mit der SARS-CoV-2-Surveillance im IGS Projekt bereitgestellt.

Die Datenerhebung am RKI erfolgt mit Ablauf der Coronavirus-Surveillanceverordnung über das IMSSC2 Labornetzwerk unter der Leitung von [FG 17 | Influenzaviren und weitere Viren des Respirationstraktes](#) und durch das [Nationale Referenzzentrum für Coronaviren](#).

Im Rahmen des IGS Projektes werden die produzierten Daten von [MF1 | Genome Competence Centre](#) bioinformatisch analysiert. Fragen bezüglich des Projektes können am besten an IGS@rki.de gerichtet werden.

Die Koordinierung und Meldedatenerfassung wird von [FG 36 | Respiratorisch übertragbare Erkrankungen](#) durchgeführt.

Die Veröffentlichung der Daten, die Datenkuration sowie das Qualitätsmanagement der (Meta-)Daten erfolgen durch das Fachgebiet [MF 4 | Fach- und Forschungsdatenmanagement](#) des RKI. Fragen zum Datenmanagement können an das Open Data Team des Fachgebiets MF4 gerichtet werden (OpenData@rki.de).

Datenerhebung

Das IMSSC2 Labornetzwerk besteht aus ~20 labormedizinischen Einrichtungen in 13 Bundesländern, die wöchentlich zufällig ausgewähltes SARS-CoV-2-positives Probenmaterial ans RKI senden. Hier erfolgt eine Ganzgenomsequenzierung sowie weiterführende phylogenetische und genombiologische Analysen, die eine Identifizierung der häufigsten in Deutschland zirkulierenden SARS-CoV-2 Linien ermöglicht. Die Ergebnisse werden auf der Webseite des RKI und in Fachzeitschriften zeitnah publiziert und tragen zur Bewertung der aktuellen epidemiologischen Lage von COVID-19 bei. Erweitert werden die IMSSC2 Daten durch Sequenzen, die durch das Nationale Konsiliarlaboratorium für Coronaviren erhoben werden. Die Daten aus

beiden Quellen werden über GitHub und andere öffentliche Datenbanken der Öffentlichkeit zur Verfügung gestellt. Ebenfalls im Datensatz enthalten sind SARS-CoV-2 Sequenzdaten aus ganz Deutschland die bis zum 31.05.2023 über den [Deutschen Elektronischen Sequenzdaten-Hub \(DESH\)](#) an das RKI übermittelt wurden.

Zuordnung von Viruslinien basierend auf Pangolin

Die Zuordnung bekannter Viruslinien zu den erhobenen Sequenzen erfolgt mittels [Pangolin](#). Mit Erscheinen einer neuen Version oder aktualisierter Liniendefinitionen von [Pangolin](#) erfolgt eine Neuordnung der Linieninformation für die gesamte Sequenzkollektion den gesamten Sequenzdatensatz. Die Informationen über die Lineage und die genutzte Pangolin Version befindet sich für jede Sequenz in den Metadaten.

Die bereitgestellten Informationen zu den Viruslinien entsprechen dem aktuellen [PANGOLIN Lineage Format](#). Nur die Spalte "Taxon" wurde zur einfacheren Nachnutzung in SEQUENCE.ID umbenannt. Zentral für die Verknüpfung der Entwicklungslinien mit den weiteren Daten ist die SEQUENCE.ID, die in allen drei Daten enthalten ist. [PANGOLIN Lineage Format](#) ist bei Widersprüchen autoritativ.

Qualitätsmanagement

Die Daten, die durch DESH erhoben wurden, durchliefen die Qualitätskontrolle (QC) der IGS am RKI nach veröffentlichten Kriterien (siehe: [rki.de - DESH Qualitätskriterien.pdf](#)). Zusätzlich wird für alle Sequenzen, inklusive IMSSC2 Proben, eine bioinformatische QC der Sequenz mit [PRESIDENT: Pairwise Sequence IDentiTy](#) durchgeführt mit einen Identitäts-Grenzwert von 70% und einen N-Grenzwert von 20%. Die Metadaten-QC überprüft die Metadaten auf fehlerhafte Daten und Eingaben, die die weitere Verarbeitung beeinflussen würden. Bei nicht bestehen der QC für Metadaten oder Sequenzdaten werden diese Daten nicht öffentlich bereitgestellt, um die hohe Qualität des öffentlichen Datensatzes zu gewährleisten.

Aufbau und Inhalt des Datensatzes

Der Datensatz umfasst genomische Sequenzen von SARS-CoV-2-Isolaten aus ganz Deutschland und zugehörige Metadaten. Im Datensatz enthalten sind:

- [übermittelte SARS-CoV-2-Genomsequenzen](#)
- [Metadaten zu den SARS-CoV-2-Genomsequenzen](#)
- Lizenz mit der Nutzungslizenz des Datensatzes
- Metadaten Datei zum Import in Zenodo
- Informationen über VOCs und VOIs
- Liste von relevanten Lineages

SARS-CoV-2-Sequenzdaten

Die SARS-CoV-2-Sequenzdaten werden im Hauptverzeichnis unter "SARS-CoV-2-Sequenzdaten_Deutschland.fasta.xz" bereitgestellt.

| [SARS-CoV-2-Sequenzdaten_Deutschland.fasta.xz](#)

Struktur der Sequenzdaten

Jede Sequenz endet mit dem Beginn eines neuen Sequenzeintrages, gekennzeichnet durch eine neue Kopfzeile, oder, im Falle des letzten Sequenzeintrages, mit dem Ende der Datei.

- Kopfzeile: ">igs_id> version=<version> id=<genome_id> <contig_index>"
- Nukleinsäuresequenz: IUB/IUPAC Standard

```
>IGS-101XX-CVDP-XX version=1 id=939421ee-feab-4b79-9f19-6dc248e0ee89 0  
NNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNACCAACCACTTCGATCTCTT...  
>IGS-101YY-CVDP-YY version=0 id=08f5d734-d135-4d2a-9680-bc5a795b2d34 0  
NNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNACCAACTCTCGGCTGCATGCT...
```

Die SARS-CoV-2-Sequenzdaten werden als **xz-komprimierte .fasta** Datei bereitgestellt. Daraus ergibt sich die Dateierendung **.fasta.xz**. Es werden Linux Zeilenumbrüche verwendet.

- Die Dateien können auf gängigen Betriebssystemen, beispielsweise mit den Programmen **7zip** oder **XZ Utils**, entpackt werden. Die Komprimierung wird vorgenommen, da insbesondere die .fasta-Dateien mehrere Gigabyte (GB) groß sind.

Die Sequenzmetadaten werden in der "SARS-CoV-2-Sequenzdaten_Deutschland.tsv.xz" bereitgestellt. Diese Daten enthalten ebenfalls die zugeordneten Viruslinien.

Die Datei [SARS-CoV-2-Sequenzdaten_Deutschland.tsv.xz](#) enthält die in der folgenden Tabelle abgebildeten Variablen und deren Ausprägungen. Ein maschinenlesbares Datenschema ist im [Data Package Standard](#) in [tableschemata_SARS-CoV-2-Sequenzdaten_Deutschland.json](#) hinterlegt:

tableschema_SARS-CoV-2-Sequenzdaten_Deutschland.json

Variable	Typ	Ausprägungen	Beschreibung
igs_id	string	Beispiel: IGS-10099-CVDP-01A2C74B-54A8-47B1-B7E4-6562C6231234	Ein eindeutiger Identifikator der Sequenzdaten und Metadaten zusammenführt. Dieser Identifikator wird als Teil der FASTA ID in den Sequenzdaten genutzt.
date_of_sampling	date	Format: YYYY-MM-DDTHH:MM:SS	Datum der Probeentnahme im ISO 8601 Format ohne Zeitzone
sequencing_platform	string	Beispiel: ILLUMINA	Die verwendete Sequenzierungs-Plattform auf Basis der von ENA zugelassenen Ontologie (siehe ena).
sequencing_reason	string	Werte: random, requested, clinical, other	Grund für die Durchführung der Sequenzierung. random : Die Probe wurde randomisiert genommen. requested : Die Probe wurde aufgrund von Bedenken/Verdacht auf eine neue Variante oder Vergleichbares genommen. clinical : Die Probe kommt aus einem klinischem Umfeld. other : Der Grund ist keiner der oben genannten.
isolation_source	string	Beispiel: Nasopharyngeal swab (specimen)	DEMIS Vokabular
lab_sequence_id	string	Beispiel: 873a7cc28d29e3f17b0544ea6e9e8436defe32f6d60649159ee8ac78d4147ac9	Vom Labor genutzte FASTA ID in verschlüsselter Form
date_of_submission	date	Format: YYYY-MM-DDTHH:MM:SS	Datum des Eingangs des Genoms am RKI im ISO 8601 Format ohne Zeitzone
version	integer	Werte: ≥0	Version der Sequenz startend mit 0
diagnostic_lab.demis_lab_id	string	Beispiel: DEMIS-10099	Identifikationsnummer des primärdiagnostischen Labors

Variable	Typ	Ausprägungen	Beschreibung
diagnostic_lab.postal_code	string	Beispiel: 50858	Postleitzahl des primärdiagnostischen Labors
sequencing_lab.demis_lab_id	string	Beispiel: DEMIS-10099	Identifikationsnummer des sequenzierenden Labors
sequencing_lab.postal_code	string	Beispiel: 50858	Postleitzahl des sequenzierenden Labors
genome.gtrs	string	Beispiel: [{"date_of_creation": "2025-05-19T11:35:46.427598", "method_version": "4.3.1", "database_version": "PUSHER-v1.32", "genomic_typing_result": "BA.2", "date_of_assignment": "2025-01-30T16:14:14.218144", "genomic_method": {"name": "Pangolin Lineage"}, "additional_information": {"note": "Usher placements: BA.2(1/1)", "conflict": 0, "qc_notes": "Ambiguous_content:0.02", "qc_status": "pass", "is_designated": false}, "date_of_modification": "2025-05-19T11:35:46.427598"}]	Genomische Typisierungs Resultate (GTR) im JSON-Format

Die Datei [SARS-CoV-2-Entwicklungslinien_berichtet.tsv](#) enthält die in der folgenden Tabelle abgebildeten Variablen und deren Ausprägungen. Ein maschinenlesbares Datenschema ist im [Data Package Standard](#) in [tableschemata_SARS-CoV-2-Entwicklungslinien_berichtet.json](#) hinterlegt:

[tableschemata_SARS-CoV-2-Entwicklungslinien_berichtet.json](#)

Variable	Typ	Ausprägungen	Beschreibung
LINEAGE	string	Beispiel: JN.1	Zugewiesene Pangolin Lineage
WHO_LABEL	string	Beispiel: Omikron	Name der Virusvariante, der von der World Health Organisation vergeben wurde
CONTRIBUTING_LINEAGES	string	Beispiel: JN.1.1.10	Pangolin Lineages, die von der Lineage abstammen

Die Datei [SARS-CoV-2-Entwicklungslinien_zu_Varianten.tsv](#) enthält die in der folgenden Tabelle abgebildeten Variablen und deren Ausprägungen. Ein maschinenlesbares Datenschema ist im [Data Package Standard](#) in [tableschemata_SARS-CoV-2-Entwicklungslinien_zu_Varianten.json](#) hinterlegt:

Variable	Typ	Ausprägungen	Beschreibung
LINEAGE	string	Beispiel: BA.2	Zugewiesene Pangolin Lineage
WHO_LABEL	string	Beispiel: Omikron	Name der Virusvariante, der von der World Health Organisation vergeben wurde
CONTRIBUTING_LINEAGES	string	Beispiel: JN.13.1	Pangolin Lineages, die von der Lineage abstammen
COLOR	any		Veraltete Variable. Ist nicht mehr relevant und wird perspektivisch entfernt.
variant_category	string	Werte: VOC , VOI	WHO Einstufung der Variante als VOC (variant of concern) oder VOI (variant of interest)

Formatierung der Sequenzmetadaten

Die Sequenzmetadaten werden als [xz-komprimierte](#), Tab-separierte .tsv-Datei bereitgestellt. Daraus ergibt sich die Dateierweiterung .tsv.xz. Der verwendete Zeichensatz der .tsv-Datei ist UTF-8. Trennzeichen der einzelnen Werte ist ein Tab `\t`. Datumsangaben sind im ISO-8601-Standard formatiert.

- Zeichensatz: UTF-8
- Datumsformat: ISO 8601
- Komprimierung: [.xz](#)
- Enthaltene Dateierweiterung: .tsv
- .tsv-Trennzeichen: Tab `\t`

Die Dateien können auf gängigen Betriebssystemen, beispielsweise mit den Programmen [7zip](#) oder [XZ Utils](#), entpackt werden. Die Komprimierung wird vorgenommen, da insbesondere die .fasta-Dateien mehrere Gigabyte (GB) groß sind.

Metadaten

Zur Erhöhung der Auffindbarkeit sind die bereitgestellten Daten mit Metadaten beschrieben. Über GitHub Actions werden Metadaten an die entsprechenden Plattformen verteilt. Für jede Plattform existiert eine spezifische Metadaten-datei, diese sind im Metadatenordner hinterlegt:

[Metadaten/](#)

Versionierung und DOI-Vergabe erfolgt über [Zenodo.org](#). Die für den Import in Zenodo bereitgestellten Metadaten sind in der [zenodo.json](#) hinterlegt. Die Dokumentation der einzelnen Metadatenvariablen ist unter <https://developers.zenodo.org/#representation> nachlesbar.

[Metadaten/zenodo.json](#)

In der zenodo.json ist neben dem Publikationsdatum (`"publication_date"`) auch der Datenstand in folgendem Format enthalten (Beispiel):

```
"dates": [
  {
    "start": "2023-09-11T15:00:21+02:00",
    "end": "2023-09-11T15:00:21+02:00",
    "type": "Created",
    "description": "Date when the published data was created"
  }
],
```

Zusätzlich beschreiben wir tabellarische Daten mithilfe des [Data Package Standards](#). Ein Data Package ist eine strukturierte Sammlung von Daten und zugehörigen Metadaten, die den Austausch und die Wiederverwendung von Daten erleichtert. Es besteht aus einer datapackage.json-Datei, die zentrale Informationen wie die enthaltenen Ressourcen, ihre Formate und Schema-Definitionen beschreibt.

Der Data Package Standard wird von der [Open Knowledge Foundation](#) bereitgestellt und ist ein offenes Format, das eine einfache, maschinenlesbare Beschreibung von Datensätzen ermöglicht.

Die Liste der in diesem Repository enthaltenen Daten ist in folgender Datei hinterlegt:

[datapackage.json](#)

Für tabellarische Daten definieren wir zusätzlich ein [Table Schema](#), das die Struktur der Tabellen beschreibt, einschließlich Spaltennamen, Datentypen und Validierungsregeln. Diese Schema-Dateien finden sich unter:

[Metadaten/schemas/](#)

Hinweise zur Nachnutzung der Daten

Offene Forschungsdaten des RKI werden auf [Zenodo.org](#), [GitHub.com](#), [OpenCoDE](#) und [Edoc.rki.de](#) bereitgestellt:

- <https://zenodo.org/communities/robertkochinstitut>
- <https://github.com/robert-koch-institut>
- <https://gitlab.opencode.de/robert-koch-institut>
- <https://edoc.rki.de/>

Lizenz

Der Datensatz "SARS-CoV-2 Sequenzdaten aus Deutschland" ist lizenziert unter der [Creative Commons Namensnennung 4.0 International Public License](#) | [CC-BY 4.0 International](#).

Die im Datensatz bereitgestellten Daten sind, unter Bedingung der Namensnennung des Robert Koch-Instituts als Quelle, frei verfügbar. Das bedeutet, jede Person hat das Recht die Daten zu verarbeiten und zu verändern, Derivate des Datensatzes zu erstellen und sie für kommerzielle und nicht kommerzielle Zwecke zu nutzen. Weitere Informationen zur Lizenz finden sich in der [LICENSE](#) bzw. [LIZENZ](#) Datei des Datensatzes.